

面向干扰耦合 5G 微基站网络的双时间尺度切片与功率协同优化方法

作者待补

2026 年 5 月 3 日

摘要

随着 5G 网络中 URLLC、eMBB 与 mMTC 三类业务的并发承载需求持续增长，如何在有限无线资源下同时满足异构业务的时延、速率与接入需求，成为网络切片资源管理中的核心问题。现有研究已经表明，分层强化学习适合处理网络切片中的长期资源协调问题，但多数工作要么聚焦 MEC 中的“通信-计算”联合分配，要么忽略无线接入侧在多基站干扰、固定资源块颗粒度和毫秒级任务演化下的双时间尺度特征。针对这一缺口，本文面向 5G 微基站场景，构建了一个由切片预算决策与功率控制决策耦合组成的双时间尺度无线资源优化框架：在 100ms 慢时间尺度上进行切片资源块划分与功率决策，在 1ms 快时间尺度上推进任务排队、传输与释放，以统一刻画异构切片 SLA、动态任务到达、用户移动信道和跨站同频干扰。

在方法设计上，本文并未将静态单站、动态单站和多站干扰场景视为彼此独立的三个题目，而是将其组织为同一研究问题的三层递进验证链。首先，在静态单站场景下采用精确枚举方法校准切片效用与资源颗粒度约束，保证模型逻辑闭合；其次，在动态单站场景下引入有限时域滚动优化，建立可解释的单站动态基线；最后，在多基站干扰耦合场景下构建“切片层离散预算 + 功率层连续控制”的分层求解框架，并使用 PPO 对两层策略进行训练与评估。实验基于已发布 benchmark 场景数据完成。结果表明，单站动态场景中 $lookahead = 2$ 的滚动优化在目标值与计算代价之间取得最佳折中；多基站场景中，分层 PPO 的多随机种子联合评估目标值达到 0.49596 ± 0.00313 ，稳定优于轻量级层次基线 0.45525。其中最佳模型实现了 0 个 URLLC 丢弃任务，说明所提出框架能够在高优先级时延业务上形成稳定保障，同时为进一步提升 eMBB 与 mMTC 的综合表现保留了明确改进空间。

关键词：5G 网络切片；双时间尺度优化；资源块分配；功率控制；分层强化学习

1 引言

5G 网络切片的核心价值在于用同一套物理基础设施同时承载多类差异显著的业务需求。对 URLLC 而言，系统需要在极短时延约束下保障传输可靠性；对 eMBB 而言，

系统更关注高吞吐与持续速率支撑；对 mMTC 而言，系统则必须面对海量设备接入和宽松但不可忽略的时延约束。这种业务异构性使得无线资源管理问题不再是单一意义上的“频谱平均分配”，而是一个同时包含业务隔离、服务保障、动态竞争与跨站协调的多目标优化问题。

进一步地，在真实无线环境中，切片资源管理还受到三个结构性难点的共同制约。第一，业务队列、用户位置和信道状态会持续演化，资源决策必须具备时间上的前瞻性。第二，系统层面通常以较粗粒度进行重配置，而业务传输却在更细粒度上发生，导致明显的双时间尺度耦合。第三，在多微基站频率复用场景下，发射功率不仅影响本链路服务质量，还会通过同频干扰改变其他链路的有效速率。因此，若只做单时刻资源分配，或者只研究单基站独立调度，都不足以完整反映切片无线资源管理的真实难度。

现有文献已经从不同角度研究了网络切片资源分配问题。Su 等对 5G 网络切片中的资源分配原理和模型进行了综述，指出切片资源管理的关键在于隔离性、可编排性和多目标约束下的资源协调 [1]。Sánchez 等进一步总结了深度强化学习在网络切片中的应用路径，认为 DRL 特别适合处理动态、不完全可观测和长期回报驱动的资源控制问题 [2]。这些工作为本文提供了研究背景，但其主要承担“问题分类与方法综述”的角色，并未给出面向本文场景的具体建模落点。

在方法层面，Chen 等研究了无线接入网络中的双层切片资源分配问题，提出了基于深度强化学习的 two-tier slicing 框架 [3]；Jiang 等在 MEC 网络中构建了服务层切片与动态资源分配相结合的两级强化学习体系，将周期性切片决策与更高频的任务级资源分配解耦 [4]。这些工作说明，将切片问题分解为“慢层预算决策 + 快层资源执行”是一条合理且有效的研究路线。然而，上述方法大多建立在虚拟化 RAN 或 MEC 的“通信-计算”联合场景之上，重点不在无线接入侧的固定 RB 颗粒度、微基站干扰耦合与功率控制问题，因此不能直接映射到本文任务。

另一方面，针对多小区干扰与功率控制的研究也已经较为丰富。例如 Kim 等在蜂窝网络中研究了基于分布式多智能体深度强化学习的发射功率控制问题，证明了多智能体 DRL 在抑制干扰和提升系统效能方面的优势 [5]。但这类工作通常以链路容量或频谱效率为主目标，较少显式纳入 URLLC、eMBB、mMTC 三类切片的异构 SLA，也很少与切片级 RB 预算决策进行统一建模。


因此，当前研究仍存在一个与本文项目高度相关的空缺：缺少一套面向无线接入侧、能够同时处理异构切片 SLA、双时间尺度任务演化、固定 RB 颗粒度以及多微基站干扰与功率控制耦合的统一建模与求解框架。本文的工作正是围绕这一缺口展开。本文的主要贡献如下：

1. 构建了一个面向 5G 微基站无线接入侧的双时间尺度切片资源模型，将 100 ms 切片重配置与 1 ms 任务执行统一到同一优化框架中，并严格沿用题面与附录给出的 SLA、任务流程和干扰规则。
2. 设计了一条从精确枚举、有限时域滚动优化到分层强化学习的递进式求解链，用静

态可解子问题保证模型闭合，用单站动态基线保证方法可解释，再用分层策略处理完整的多站耦合场景。

3. 在已发布 benchmark 场景数据上验证了该框架的有效性：单站动态场景下滚动优化深度存在明确最优折中，多站场景下分层 PPO 在多随机种子下稳定优于轻量级基线，并对 URLLC 形成了稳定的硬约束保障。

为避免将前三问写成彼此割裂的工程结果，本文后续始终按照图1所示的证据链展开：问题 1 承担模型校准作用，问题 2 验证动态队列下的时间前瞻价值，问题 3 再进入完整的多基站干扰耦合与功率控制场景。换言之，三组实验共同服务于同一个研究命题，即双时间尺度切片预算与功率控制如何在异构 SLA 约束下提升长期平均服务质量。



Unified objective: long-term average service utility under heterogeneous slice SLA

Two time scales: 100 ms slice/power decisions and 1 ms task service execution

图 1: 前三问在本文中的统一证据链。图中 Q1、Q2 和 Q3 分别对应静态校准、动态基线与多站耦合控制三个复杂度层级。

2 相关工作

已有研究大致可以分为三条与本文密切相关的技术路线。

第一类工作关注网络切片中的资源分配总体框架。相关综述指出，切片资源管理的核心不只是频谱切分本身，还包括对不同业务时延、速率和可靠性偏好的统一表示 [1, 2]。这一类工作为本文提供了“为什么必须同时考虑业务异构性与资源约束”的理论背景。

第二类工作关注切片资源管理中的分层或双层控制结构。Chen 等在无线接入网络中提出两层切片资源分配与竞价联合机制 [3]；Jiang 等则在 MEC 场景下使用两级强化学习分别处理服务层切片与动态资源分配 [4]。这类工作启发了本文将问题拆解为慢时间尺度预算决策与快时间尺度服务执行两个层级，但本文没有照搬其 MEC 中的计算资源块设定，而是将第二层重新映射为无线接入侧更关键的功率控制与干扰协调问题。

第三类工作关注干扰耦合场景下的功率控制。此类方法通常使用优化算法或深度强化学习直接最大化频谱效率、链路吞吐或能效 [5, 6]。然而，当研究对象从单一链路性

能扩展到异构切片 SLA 时，仅考虑功率控制不足以回答“频谱预算如何在业务间切分”这一问题。因此，本文采用切片预算与功率控制协同优化的思路，把干扰控制纳入更高层级的切片资源管理中。

总体来看，现有研究已经分别在切片框架、分层控制和功率优化方面形成积累，但仍缺少一套面向无线接入侧、同时处理异构切片 SLA、双时间尺度任务演化、固定 RB 颗粒度以及多微基站干扰与功率控制耦合的统一方法。本文工作的定位正是填补这一空白。

3 系统模型与问题表述

3.1 网络场景与数据来源

本文研究对象为由多个微基站构成的 5G 无线接入网络。每个微基站持有 50 个资源块，单个资源块的频域带宽为 360 kHz，时域跨度为 1 ms。所有建模参数、业务 SLA、任务流程和干扰形式均来自项目仓库中的题面、附录以及配套 Excel 数据文件。需要强调的是，本文实验使用的是已发布 benchmark 场景数据，而不是现场测量数据；因此本文定位为 benchmark-driven method study，而非 measurement study。

3.2 双时间尺度建模

题面规定系统每 100 ms 决策一次资源配置方案，而附录中任务的排队、占用与释放以 1 ms 为基本执行粒度。因此本文将系统控制划分为两个时间层次：

- 慢时间尺度：每 100 ms 做一次切片资源预算更新；在多基站场景下同时更新基站-切片发射功率；
- 快时间尺度：在每个 1 ms 微时隙内，根据当前切片预算与信道状态推进任务服务、队列变化和资源释放。

这一建模方式的必要性在于：若只保留 100 ms 粒度，则 URLLC 的 5 ms 时延约束无法被正确表达；若完全按 1 ms 做全局联合优化，则状态与动作空间会迅速膨胀，导致求解代价难以接受。

3.3 切片业务与参数标定

本文考虑三类切片业务：URLLC、eMBB 和 mMTC。其业务语义锚定于 3GPP 中对低时延高可靠、高吞吐宽带和大连接低速率业务的定义，但实验中的具体数值采用已发布 benchmark 场景进行参数化，而不将其表述为某一单一标准 5QI 条目的直接拷贝。三类业务的参数见表1。

表 1: 三类切片的业务语义与 benchmark 参数化

切片	RB 占用量	速率目标 (Mbps)	时延上限 (ms)	惩罚系数 β_s	其他说明
URLLC	10	10	5	5	时延折扣 $\alpha_u = 0.95$
eMBB	5	50	100	3	吞吐优先
mMTC	2	1	500	1	接入优先

其中, $\alpha_u = 0.95$ 与 $\beta = (5, 3, 1)$ 不是 3GPP 标准中的固定参数, 而是 benchmark 评价函数中的校准常数。其作用分别是: 一方面用 α_u 刻画 URLLC 任务在截止前的时延敏感性; 另一方面用 β 体现三类业务在超出 SLA 后不同的违约代价强度。

3.4 切片资源预算约束

设第 t 个慢时间尺度决策周期内, 基站 b 分配给切片 $s \in \{u, e, m\}$ 的资源块数量为 $x_{b,s,t}$, 则有

$$\sum_{s \in \{u, e, m\}} x_{b,s,t} \leq R^{\max} = 50, \quad \forall b, t. \quad (1)$$

同时, 切片资源预算必须满足颗粒度约束

$$x_{b,u,t} \in 10\mathbb{Z}_+, \quad x_{b,e,t} \in 5\mathbb{Z}_+, \quad x_{b,m,t} \in 2\mathbb{Z}_+. \quad (2)$$

因此, 每个切片在单个微时隙内可并行服务的最大用户数为

$$n_{b,s,t} = \left\lfloor \frac{x_{b,s,t}}{g_s} \right\rfloor, \quad (3)$$

其中 g_s 表示切片 s 的每任务资源块占用量。

3.5 传输、队列与干扰模型

根据附录中的信号传输模型, 用户 i 在基站 b 服务下的接收信号功率为

$$P_{i,b,t}^{\text{rx}} = 10^{\frac{P_{b,s,t}^{\text{dBm}} - L_{i,b,t}}{10}} \cdot |h_{i,b,t}|^2, \quad (4)$$

其中 $L_{i,b,t}$ 为大尺度路径损耗, $h_{i,b,t}$ 为小尺度瑞丽衰落。若多微基站在同频资源上同时传输, 则用户 i 的信干噪比为

$$\text{SINR}_{i,b,t} = \frac{P_{i,b,t}^{\text{rx}}}{\sum_{b' \neq b} P_{i,b',t}^{\text{rx}} + N_0}, \quad (5)$$

其中 N_0 表示噪声功率。由香农公式得到瞬时速率

$$r_{i,b,t} = g_s W_{\text{RB}} \log_2(1 + \text{SINR}_{i,b,t}). \quad (6)$$

第 1、2 层场景采用固定发射功率 30 dBm；第 3 层场景中允许每个基站每类切片的发射功率在 10 至 30 dBm 之间调节，即

$$P_{b,s,t}^{\text{dBm}} \in [10, 30]. \quad (7)$$

在任务流程上，切片预算先于微时隙执行确定；任务到达后进入所属切片队列，按编号顺序和 RB 可用性依次占用资源块并接受服务，完成后释放资源。对于动态场景，队列状态在每个微时隙内更新；对于多基站场景，当前实现采用最近微基站接入作为显式建模假设，接入模式优化不纳入本文研究范围。

3.6 统一效用函数

三类切片的服务质量函数采用任务级定义。

对 URLLC 任务 i ，若其总时延 d_i 不超过时延上限 $\tau_u^{\max}$ ，则其服务质量定义为

$$q_i^{(u)} = \alpha_u^{d_i}, \quad d_i \leq \tau_u^{\max}; \quad (8)$$

否则

$$q_i^{(u)} = -\beta_u. \quad (9)$$

对 eMBB 任务 i ，若总时延满足约束，则其服务质量按有效服务速率相对于目标速率的达成比例计算：

$$q_i^{(e)} = \min \left(\frac{r_i^{\text{eff}}}{C_e^{\min}}, 1 \right), \quad d_i \leq \tau_e^{\max}, \quad (10)$$

否则

$$q_i^{(e)} = -\beta_e. \quad (11)$$

对 mMTC 任务，附录强调其核心是接入成功性。由于当前数据与代码采用任务级推进，因此本文将操作化为：若任务在时延门限内完成，则计为一次成功接入并赋值 1，否则记为超时惩罚

$$q_i^{(m)} = \begin{cases} 1, & d_i \leq \tau_m^{\max}, \\ -\beta_m, & d_i > \tau_m^{\max}. \end{cases} \quad (12)$$

设第 t 个决策周期内切片 s 完成评估的任务集合为 $\mathcal{D}_{s,t}$ ，对应切片权重为 w_s ，则系统目标写为长期平均加权切片效用：

$$J = \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T \sum_{s \in \{u,e,m\}} w_s \cdot \frac{1}{|\mathcal{D}_{s,t}|} \sum_{i \in \mathcal{D}_{s,t}} q_i^{(s)}. \quad (13)$$

本文默认采用等权设置 $w_u = w_e = w_m = \frac{1}{3}$ ，并在后续通过参数灵敏度分析验证结论对校准常数扰动的稳健性。

4 求解框架

4.1 总体思路

如果直接在完整多站场景上把所有决策变量一次性联合优化，问题会同时面临离散切片预算、连续功率控制、随机队列演化与跨站干扰反馈，难以保证模型正确性和算法稳定性。因此本文采用“由简入繁”的三级求解链：

1. 用静态精确解验证效用定义与离散资源约束是否闭合；
2. 用单站动态滚动优化建立可解释的时间演化基线；
3. 用分层强化学习求解完整的多站干扰耦合问题。

这种写法强调的是模型如何从简化场景走向完整场景，而不是简单按赛题编号罗列答案。

4.2 静态校准层：精确枚举

在最简单的单站单时刻场景中，三类切片只需要在 50 个 RB 内进行整数划分，同时满足 10/5/2 的颗粒度约束。由于动作空间规模较小，完全可以枚举全部可行分配方案并计算对应服务质量。该层的作用不是展示复杂算法，而是验证以下三点：

- 给定的 QoS 评价函数是否与任务流程和资源颗粒度一致；
- 资源块粒度、速率公式和时延约束是否会产生逻辑冲突；
- 在最简设置下，系统最优解是否可以由精确方法得到。

本文代码中对应脚本为 `channel_data` 等 2 个文件/`solve_q1.py`。该脚本对所有满足资源块约束的切片预算进行穷举，对每一组预算分别计算 URLLC、eMBB 与 mMTC 的任务级效用均值，并选出综合目标最大的方案。

4.3 单站动态层：有限时域滚动优化

在引入 1000 ms 时域、动态任务流和信道变化后，单站场景已经具有明显的时序决策特征。此时本文采用有限时域滚动优化思路：在每个 100 ms 决策时刻，对若干未来窗口进行前瞻模拟，评估当前动作对后续队列积压和 SLA 满足程度的影响，并据此选择当前切片预算。

设当前时刻状态为 S_t ，合法动作集合为 $\mathcal{A}(S_t)$ ，向前搜索深度为 H ，则第 t 个窗口的优化可以写为

$$a_t^* = \arg \max_{a_t \in \mathcal{A}(S_t)} \left\{ \Delta J(S_t, a_t) + \max_{a_{t+1:t+H-1}} \sum_{k=t+1}^{t+H-1} \Delta J(S_k, a_k) \right\}, \quad (14)$$

其中 $\Delta J(S_t, a_t)$ 表示当前动作在本窗口内带来的效用增量。代码中对应实现为 `q2_mpc.py`。具体流程如下：

1. 枚举所有满足切片颗粒度约束的预算动作；
2. 对每个动作进行 H 步前瞻仿真；
3. 在窗口内部按 1 ms 粒度推进任务服务；
4. 对在 1000 ms 终点仍未完成的任务施加终端惩罚；
5. 选择当前窗口投影价值最大的动作。

这一层的意义主要体现在两个方面：从方法论上，它提供了一个不依赖神经网络训练、具备较强可解释性的动态单站基线；从研究叙事上，它起到了连接静态可解模型与完整多站强化学习模型的桥梁作用，说明即使在不考虑跨站干扰时，时间前瞻本身也足以改变资源配置效果。

4.4 多站耦合层：分层强化学习

当系统扩展到多微基站频率复用场景时，切片资源分配与发射功率控制会通过干扰机制发生显著耦合。此时若仍采用单层统一动作表示，会同时面临高维离散-连续混合动作空间和稀疏长期回报问题。为此，本文借鉴 Jiang 等在 MEC 场景中提出的“服务层切片 + 动态资源分配”两级思想 [4]，但根据本文的无线接入侧特征重新进行映射：

- 上层负责基站-切片 RB 预算决策，是一个离散动作问题；
- 下层负责在切片预算确定后对基站-切片发射功率进行连续控制，是一个连续动作问题。

在当前实现中，上层策略学习环境记为 $\mathcal{E}_{\text{slice}}$ 。其状态包括各基站各切片的队列长度、队首等待时间、近期到达情况、关联用户集合与统计信道强度；动作是每个基站在离散动作空间中的切片预算索引；奖励由切片代理得分、功率正则项、干扰正则项和公平性奖励组成。对应脚本为 `q3_sb3.py train-slice`。

在下层功率控制环境 $\mathcal{E}_{\text{power}}$ 中，状态由全局观测与上层给出的切片预算拼接而成；动作为每个基站每类切片的连续功率控制量，经线性映射后落在 $[10, 30]\text{ dBm}$ 区间；奖励沿用相同的统一结构。对应脚本为 `q3_sb3.py train-power`。

在训练层面，上下两层均采用 PPO。其一，PPO 对连续动作功率控制具有天然适应性；其二，PPO 在当前问题规模下比更复杂的多智能体算法更容易获得稳定训练。通过先训练切片层、再在切片模型条件下训练功率层的方式，系统实现了对离散预算与连续功率的分解求解。

5 实验设置与结果分析

5.1 实验数据与评价口径

实验部分与求解框架保持同构组织，即先用静态单站结果检查模型闭合性，再用动态单站结果分析时间前瞻带来的收益与代价，最后用多站结果检验分层切片-功率协同控制的有效性。实验数据均来自项目仓库中的已发布 benchmark 场景实例。其中，静态单站场景采用 channel_data 等 2 个文件/channel_data.xlsx；动态单站场景采用 channel_data 等 2 个文件 (1)/channel_data.xlsx；多站场景采用 BS2 等 5 个文件/BS1.xlsx、BS2 等 5 个文件/BS2.xlsx、BS2 等 5 个文件/BS3.xlsx 和 BS2 等 5 个文件/taskflow.xlsx。

评价指标主要包括：

- 综合目标值 J ；
- 各切片完成任务数与丢弃任务数；
- 各切片平均时延；
- eMBB 平均服务速率；
- 在多站场景下进一步记录平均发射功率与平均干扰比。

5.2 静态单站校准实验

静态单站场景采用精确枚举进行校准。当前结果显示，在默认等权设置下存在三组并列最优的切片分配方案：

$$(30, 10, 10), \quad (20, 20, 10), \quad (20, 10, 20).$$

它们对应相同的综合目标值 0.980771，且三类切片效用分别为 $Q_u = 0.993482$ 、 $Q_e = 0.948832$ 、 $Q_m = 1.000000$ 。这一结果说明，当前静态场景下系统资源尚未紧张到使最优解唯一，模型更适合作为效用校准与可行性验证使用，而不是全文的主要性能展示部分。

图2进一步说明，静态校准层的结论并不是某一个单点配置偶然最优，而是在当前任务规模下存在多个等效资源划分。这一现象反过来验证了本文的递进式设计必要性：若只停留在问题 1，无法充分体现动态队列和干扰耦合对资源管理策略的影响。

5.3 动态单站对照实验

动态单站场景通过 q2_mpc.py 实现有限时域滚动优化。表2给出了不同前瞻深度下的主结果。




图 2: 静态单站场景下三组并列最优 RB 划分。结果由 channel_data 等 2 个文件/solve_q1.py 在 channel_data 等 2 个文件/channel_data.xlsx 上枚举得到。

表 2: 不同前瞻深度下的 Q2 结果

前瞻深度	目标值	运行时间 (s)	结论
1	0.8492915	—	前瞻不足
2	0.8986440	36.08	最优折中
3	0.8877485	645.62	代价过高且收益下降

可以看到，从 $lookahead = 1$ 提升到 $lookahead = 2$ 时，系统目标值显著上升，说明适度的时间前瞻确实能够改善动态资源配置效果；但进一步增加到 $lookahead = 3$ 后，目标值并未继续提升，计算代价却急剧增大。这表明更深层的滚动预测在当前问题规模和数据下已经出现边际收益递减。




图 3: 动态单站场景中前瞻深度对目标值与运行时间的影响。目标值来自 `outputs/q2_mpc/lookahead*.json`，运行时间来自对应 `lookahead*_time.txt` 文件。

以 $lookahead = 2$ 为例，系统实现了：URLLC 完成 216、丢弃 1、平均时延 2.4960 ms；eMBB 完成 1931、丢弃 25、平均时延 16.7218 ms；mMTC 完成 7010、丢弃 0、平均时延 15.7955 ms。这说明滚动优化已经能够较好平衡三类切片的竞争关系，为多站强化学习层提供了一个可解释的强基线。




图 4: $lookahead = 2$ 时 10 个决策窗口内的 RB 预算序列。图中每根柱的总高度为 50 个 RB，显示滚动优化会随队列压力在 eMBB 和 mMTC 之间重新分配资源。

结合图3与图4可以看出，问题 2 的关键结论不只是“某个动作序列最优”，而是动态

前瞻机制能够根据队列积压状态调整切片预算；同时，过深前瞻会显著放大枚举搜索代价。因此该层在全文中承担的是动态基线与复杂度边界的作用。

5.4 多站干扰耦合实验

多站场景由 `q3_hierarchical_rl.py` 与 `q3_sb3.py` 完成训练和评估。表3给出了当前多随机种子联合评估结果。

表 3: Q3 多随机种子联合评估结果

方法/随机种子	目标值	URLLC 丢弃数	备注
轻量级层次基线	0.4552520	—	Numpy actor-critic
PPO, seed=7	0.4918838	0	分层训练
PPO, seed=17	0.4994806	0	最佳展示结果
PPO, seed=27	0.4965230	0	分层训练
均值 $\pm$ 标准差	0.49596 ± 0.00313	—	稳定性较好

从研究叙事上，这组结果至少说明两点。第一，分层结构相较于轻量级基线具有稳定而非偶然的性能提升；第二，三组随机种子之间的波动较小，说明当前方法的性能并不依赖某一次幸运训练结果，而已经具备一定可重复性。




图 5: 多站干扰耦合场景中的多随机种子目标值对比与最佳模型完成率。结果来自 `outputs/q3_rl/short_run_metrics.json` 和 `outputs/q3_sb3/q3_combined_eval*_10k.json`。

以最佳的 $seed = 17$ 为例，联合评估结果显示：综合目标值为 0.4994806473699616；URLLC 完成 559 个任务、丢弃 0 个、平均时延 1.2795 ms；eMBB 完成 5406 个任务、丢弃 587 个、平均时延 99.9393 ms；mMTC 完成 10527 个任务、丢弃 10556 个、平均时

延 398.5841 ms；eMBB 平均服务速率为 112.2346 Mbps；平均发射功率为 0.1032 W；平均干扰比为 0.3555。

这些结果支撑如下更严谨的结论：当前分层框架已经能够对 URLLC 形成稳定的硬约束保障，并在综合目标上取得相对于轻量级基线的稳健提升；但 eMBB 仍处于接近 100 ms 边界的紧约束区间，mMTC 也仍然是最难服务的切片。换句话说，本文方法已经证明“整体框架有效”，但并不意味着所有业务都已经达到充分优化状态。




图 6: $seed = 17$ 切片层 PPO 训练曲线。该图由 `outputs/q3_sb3/q3_slice_ppo_seed17_10k_curves.png` 同步至论文图目录，用于展示训练过程中的目标值提升趋势。

图5和图6分别从最终结果和训练过程两个角度支撑多站层结论：分层 PPO 相较于轻量级层次基线具有稳定优势，且训练过程中官方目标值随训练推进整体上升。不过，最佳模型对 mMTC 的完成率仍不足，说明当前策略更偏向保障 URLLC 和 eMBB 时延边界，后续仍需通过奖励权重调节或更强的多智能体协同机制继续改进。

5.5 参数灵敏度分析

考虑到效用函数中的 α_u 与 $\beta = (\beta_u, \beta_e, \beta_m)$ 属于 benchmark 校准常数，本文进一步对其进行参数灵敏度分析。第二问仍采用前文所述附件 2 数据文件和 $lookahead = 2$ 滚动优化；第三问仍采用前文所述附件 3 多基站数据文件，并在每组参数下重新训练

切片层与功率层 PPO。为控制训练成本，第三问灵敏度实验固定 $seed = 17$ 、训练步数 10000、评估回合数为 1。结果文件来自 `sensitivity/` 目录下的四组 JSON 实验记录。

表 4: 第二问滚动优化的参数灵敏度结果

扰动类型	参数取值	目标值	丢弃数 (URLLC/eMBB/mMTC)	eMBB 平均速率 (Mbps)
α_u	0.90	0.832790	1/121/149	51.326
α_u	0.93	0.883140	1/46/0	45.019
α_u	0.95	0.898644	1/25/0	44.997
α_u	0.97	0.913442	1/25/0	45.094
β	(4,2,1)	0.904440	1/25/0	44.997
β	(5,3,1)	0.898644	1/25/0	44.997
β	(6,4,2)	0.892847	1/25/0	44.997

表4说明，第二问结果对 α_u 更敏感：当 α_u 从 0.90 提高到 0.97 时，综合目标值由 0.832790 升至 0.913442，同时 eMBB 和 mMTC 丢弃数明显下降。其原因并不是单纯的评价尺度改变，而是滚动优化会在不同 URLLC 时延折扣下重新选择切片预算，从而改变后续队列状态。相比之下，在 β 扰动下，三组实验选择出的完成数、丢弃数和平均时延完全一致，目标值仅随惩罚强度重新标定而单调下降。这表明当前动态单站策略结构对惩罚系数扰动较稳定，但目标值本身仍然依赖惩罚尺度。

表 5: 第三问分层 PPO 的参数灵敏度结果

扰动类型	参数取值	目标值	丢弃数 (URLLC/eMBB/mMTC)	平均功率 (W)	平均干扰比
α_u	0.90	0.480151	0/587/10556	0.1032	0.3555
α_u	0.93	0.491599	0/587/10556	0.1032	0.3555
α_u	0.95	0.499481	0/587/10556	0.1032	0.3555
α_u	0.97	0.507570	0/587/10556	0.1032	0.3555
β	(4,2,1)	0.532130	0/587/10556	0.1032	0.3555
β	(5,3,1)	0.499481	0/587/10556	0.1032	0.3555
β	(6,4,2)	0.296168	0/587/10556	0.0981	0.3616

表5和图7进一步给出了完整多站场景下的验证。与第二问不同，第三问在 α_u 扰动下的完成数、丢弃数、平均功率和平均干扰比均保持不变，目标值随 α_u 升高而上升，主要反映 URLLC 截止前时延折扣的重新标定，而不是服务过程发生了显著变化。在 β 扰动下，(6,4,2) 使目标值明显下降，原因是 eMBB 与 mMTC 仍存在大量丢弃任务，较大的违约惩罚会被直接放大。该结果支持两个结论：第一，本文关于 URLLC 稳定保障的结论对参数扰动较稳健；第二，mMTC 服务不足并非单一参数设置造成，而是当前分层 PPO 策略和训练强度下仍然存在的结构性短板。




图 7: 第二问与第三问中 α_u 和 β 扰动对综合目标值的影响。结果由 sensitivity/目录中的灵敏度实验 JSON 文件整理得到。

6 讨论

从写作角度, 本文最重要的不是把所有附件都“做完”, 而是形成一条清晰的研究叙事: 为什么这个问题重要, 现有方法哪里不够, 本文如何把问题拆成可解释的层次, 并且为什么这种拆法是合理的。沿着这个逻辑, 静态校准层、动态单站层和多站干扰层并不是三个互相孤立的答案, 而是同一个研究问题在复杂度上的三级递进。

当前结果也提示了两点需要在正式论文中诚实说明的局限性。其一, 接入模式仍采用最近基站规则, 尚未纳入联合优化; 其二, mMTC 的服务表现仍有较大提升空间, 灵敏度分析进一步说明该问题并非由某一组 α_u 或 β 参数偶然导致, 而更可能来自当前奖励设计、训练强度与多站协同机制本身。

7 结论

本文围绕 5G 微基站网络中的异构切片资源管理问题, 构建了一个面向无线接入侧的双时间尺度切片与功率协同优化框架。与将赛题拆解为若干独立子问的写法不同, 本文将静态单站、动态单站与多站干扰场景统一组织为一条由模型校准、动态基线到完整耦合控制的递进式研究链, 并据此分别采用精确枚举、有限时域滚动优化和分层强化学习进行求解。基于已发布 benchmark 场景的实验结果表明, 该框架在单站场景下能够清晰揭示前瞻深度与计算代价之间的折中关系, 在多站场景下则能够以较稳定的方式提升综合服务目标, 并形成对 URLLC 业务的可靠保障。参数灵敏度分析进一步表明, 主要

结论不依赖单一校准常数组合，但 mMTC 服务不足仍是需要后续重点改进的问题。未来工作可进一步将接入模式决策、能效目标和更强的多智能体协同机制纳入统一框架，以提升对 eMBB 与 mMTC 的综合服务能力。

参考文献

- [1] Yang Su et al. Resource allocation for network slicing in 5g telecommunication networks: A survey of principles and models. *IEEE Network*, 33(6):172–179, 2019.
- [2] José Sánchez et al. Deep reinforcement learning for resource management on network slicing: A survey. *Electronics*, 11(3):303, 2022.
- [3] Xiaolong Chen et al. Two tier slicing resource allocation algorithm based on deep reinforcement learning and joint bidding in wireless access networks. *Sensors*, 22(9):3495, 2022.
- [4] Shurui Jiang, Jun Zheng, Feng Yan, and Shuyuan Zhao. Reinforcement-learning-based network slicing and resource allocation for multi-access edge computing networks. *IEEE Transactions on Cognitive Communications and Networking*, 10(3):1132–1143, 2024.
- [5] J. Kim et al. Distributed multi-agent deep reinforcement learning based transmit power control in cellular networks with local csi. *Sensors*, 25(6):1763, 2025.
- [6] J. Kim and J. So. Energy-efficient deep reinforcement learning assisted resource allocation for 5g-ran slicing. *Sensors*, 25(3):933, 2025.